山东大学 计算机科学与技术 学院

机器学习(双语) 课程实验报告

学号: 201705130113 | 姓名: 黄瑞哲 | 班级: 计科 17.3

实验题目: K-Means

实验学时: 4 实验日期: 2019.12.6

实验目的:

1. 掌握 k 均值中的 KMeans 算法

2. 应用 KMeans 算法实现图片的像素压缩

硬件环境:

Intel Core i5-8300H @ 2.3GHz

软件环境:

Windows10 Pro 1903

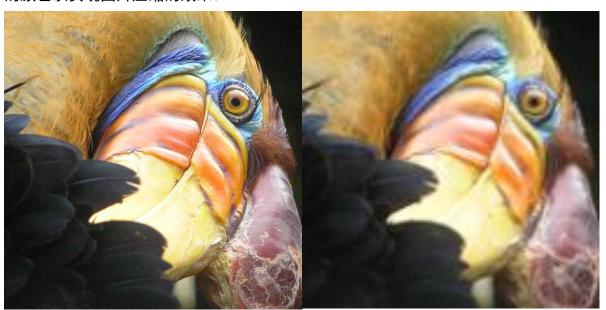
Python 3.7

Visual Studio Code

实验步骤与内容:

1. 数据集

数据集中包含两张 tiff 格式的图片,一张像素是 538x538 的,另一张是 128x128 的。每个像素点是的颜色值是 24 位的,由 3 个 8 位的、范围在[0,255]之间的数构成,分别表示红 R、绿 G、蓝 B。现在我们的任务是在图片中选取 16 个颜色来替代每个像素点中的颜色以实现图片压缩的效果。



2. KMeans 算法

KMeans 是实现聚类的一种算法,分为3步

- 一、随机选取 K 个聚类中心
- 二、使用欧几里得距离计算出每个样本数据与哪一个聚类中心更相似

$$c^{(i)} := \arg\min_{j} \|x^{(i)} - \mu_{j}\|^{2}$$

三、使用该类中所有的样本数据重新计算聚类中心

$$\mu_j := \frac{\sum_{i=1}^{m} 1\{c^{(i)} = j\}x^{(i)}}{\sum_{i=1}^{m} 1\{c^{(i)} = j\}}$$

当中心点变化幅度较小或满足一定的迭代次数后算法停止

3. 图片压缩

算法作用在一个三维空间中,这个空间是以 RGB 三个颜色值为基底的三维空间。那么每个点的 RGB 值便是这个空间中的一个点,将所有像素点的 RGB 值放入该三维空间中然后做 k=16 的聚类,其中 16 个初始聚类中心从所有的颜色值中随机产生。完成聚类后可以知道每个点属于哪一个聚类中心,然后可以将这个点的 RGB 值替换为对应的聚类中心的 RGB 的值,最终再将图片还原即可。



可以看出颜色的对比度有了明显的减小,而且出现了粗糙的颜色轮廓。

结论分析与体会:

KMeans 算法的思路还是非常清晰的,使用样本数据更新聚类中心,然后根据新的聚类中心来分类,不断循环,最后能够得到一个较好的结果。而且算法实现起来也是非常简单,只需要按照算法一步步实现即可。但是自己手写的 KMeans 算法与现有的算法代码库中的 KMeans 在运行效率上还是有很大的区别: 手写的算法迭代 50 多次可能需要将近半分钟的时间,而代码库如 sklearn 中实现的 KMeans 仅仅需要几秒就可以求得结果。

还有一点, python 的绘图库中要求 RGB 的颜色要么是[0, 1]的浮点数, 要么是[0, 255]的整型, 因此在导入样本数据的时候需要将读入的数据/255 将其转换为[0, 1]之间的浮点数然后再进行运算, 否则得到的结果因为会是浮点数, 渲染图片的时候将会是错误的。

```
附录:程序源代码
import numpy as np
import matplotlib.pyplot as plt
import matplotlib. image
# from sklearn.cluster import KMeans
class KMeans:
    def __init__(self, n_clusters, max_iter=200):
        self.n_clusters = n_clusters
        self.max_iter = max_iter
    def fit(self, X):
        m, n = np. shape(X)
        assert self.n clusters <= m
        self.__random_cluster_centers_(X)
        self.labels_ = [0 for i in range(m)]
        for iter in range(self.max iter):
            for i in range (m):
                k = 0
                for j in range(1, self.n_clusters):
                         np. dot(X[i]

    self.cluster centers [j],

                                                                          X[i] -
self.cluster_centers_[j]) \langle np.dot(X[i] - self.cluster_centers_[k], X[i] -
self.cluster centers [k]):
                        k = j
                self. labels [i] = k
            for j in range (self. n clusters):
                sum x = np. zeros(n)
                sum_cnt = 0
                for i in range (m):
                    if self.labels_[i] == j:
```

```
sum x += X[i]
                         sum_cnt += 1
                if sum cnt > 0:
                    self.cluster_centers_[j] = sum_x / sum_cnt
    def __random_cluster_centers_(self, X):
        import random
        ind = random. sample([i for i in range(len(X))], self. n_clusters)
        self.cluster centers = []
        for i in ind:
            self.cluster_centers_.append(X[i])
        self.cluster_centers_ = np. array(self.cluster_centers_)
if __name__ == "__main__":
    def image_reconstruction(cluster_centers_, labels_, w, h):
        channel = np. shape(cluster_centers_)[1]
        image = np. zeros((w, h, channel))
        ind = 0
        for i in range(w):
            for j in range(h):
                image[i][j] = cluster_centers_[labels_[ind]]
        return image
    bird = matplotlib. image. imread("exp6/data/bird small.tiff")
    bird = np. array(bird, dtype=np. uint)
    m, n, channel = np. shape(bird)
    kmeans = KMeans(n_clusters=16, max_iter=50)
    kmeans.fit(np.reshape(bird, (m * n, channel)))
    bird compressed
                           =
                                    image_reconstruction(kmeans.cluster_centers_,
kmeans.labels_, m, n)
    matplotlib.image.imsave("exp6/data/bird_compressed.tiff", bird_compressed)
    plt. figure (1)
    plt.title("Origin image")
    plt.axis("off")
    plt.imshow(bird)
    plt. figure (2)
    plt.title("Compressed image (16 colors)")
    plt.axis("off")
    plt. imshow(bird_compressed)
    plt.show()
```